### SRA-Explorer+Aspera才是打开SRA的正确方式!

自从去年NCBI取消SRA对FTP下载的支持后,下载SRA公共数据变的麻烦起来,也慢了很多,虽然 prefecth直接通过SRR号直接下载数据,但是也取消了对FTP的支持,只能通过HTTPS方式下载,速度巨 慢。虽然NCBI提供了AWS和google下载方式,但是两者注册比较麻烦,基本上是收费的。

以前的NCBI SRA支持Aspera方式高速下载,速度基本维持在100Mb/s左右。但是目前的SRA取消对FTP 支持后,直接无法通过anonftp@ftp.ncbi.nlm.nih.gov获取到SRA的数据。

那么问题来了,到底还有没有好的SRA下载方式呢? 答案是有的,而且很方便。

我们以一篇最新的Scientific Data文章为例,演示怎么快速下载SRA数据。

www.nature.com/scientificdata

# SCIENTIFIC DATA



## **OPEN** Highly accurate long-read HiFi DATA DESCRIPTOR sequencing data for five complex genomes


Ting Hon<sup>1</sup>, Kristin Mars<sup>1</sup>, Greg Young<sup>1</sup>, Yu-Chih Tsai <sup>10</sup>, Joseph W. Karalius <sup>10</sup>, Jane M. Landolin<sup>2</sup>, Nicholas Maurer<sup>3</sup>, David Kudrna<sup>4</sup>, Michael A. Hardigan<sup>5</sup>, Cynthia C. Steiner<sup>6</sup>, Steven J. Knapp<sup>⑤</sup><sup>5</sup>, Doreen Ware<sup>⑥</sup><sup>7,8</sup>, Beth Shapiro<sup>⑥</sup><sup>3,9</sup>, Paul Peluso<sup>1</sup> & David R. Rank<sup>⑥</sup><sup>1</sup>

文章测了五个物种的基因组数据,而且是通过PacBio HIFI 测序方法。


Organism	HiFi library size (kb)	Sequel II Runs (number)	Bases > RQ20 (Gb)	Average RL (kb)	Reads (Millions)	Quality Value* (avg)	Data Record
M. musculus	15.9	2	66.5	16.4	4.1	31	SRR11606870 <sup>37</sup>
Z. mays	15.0	2	48.1	15.6	3.1	30	SRR11606869 <sup>38</sup>
F. × ananassa	23.0	1	29.7	21.7	1.4	28	SRR11606867 <sup>39</sup>
R. muscosa	15.8	8	189.1	15.7	12.1	31	SRR11606868 <sup>40</sup>
ATCC MSA-1003	14.1	2	59.1	10.5	5.6	35	SRR11606871 <sup>41</sup>

文章提供的中SRA编号是: SRP258341


我们请上今天的主角: SRA Explorer https://sra-explorer.info/




#### 直接输入SRP258341



#### 得到19条记录:




#### 依次操作,加入购物车:



然后可以直接选择下载fastq格式的文件,而无需下载SRA格式,还得通过fasterq-dump转化格式。很方便,是不是?



点进去,发现SRA Explorer已经给出了下载脚本,还能直接修改下载的数据名字,添加了物种,数据类型等信息。非常地人性化。



通过Copy或者Download就可以得到下载的脚本,竟然同时支持Linux和MacOS系统,后者需要打开终 端操作。 当然,如果只对HiFi数据感兴趣,可以在加入购物车之前就选择,或者在脚本中选择亦可。其它的14个是HiFi数据的原始数据。

```
RR11606867_subreads.fastq.gz . && mv SRR11606867_subreads.fastq.gz SRR11606867_Fragaria_x_ananassa_Royal_Royce_PacBio_HiFi_Reads_FASTQ_subreads.fastq.gz
RR11606868_subreads.fastq.gz . && mv SRR11606868_subreads.fastq.gz SRR11606868_Rana_muscosa_PacBio_HiFi_Reads_FASTQ_subreads.fastq.gz
RR11606870_subreads.fastq.gz . && mv SRR11606870_subreads.fastq.gz SRR11606870_Mus_musculus_C57_BL6J_PacBio_HiFi_Reads_FASTQ_subreads.fastq.gz
BAM
RR11606869_subreads.fastq.gz . && mv SRR11606869_subreads.fastq.gz SRR11606869_Zea_mays_B73_PacBio_HiFi_Reads_FASTQ_subreads.fastq.gz
RR11606871_subreads.fastq.gz . && mv SRR11606871_subreads.fastq.gz SRR11606871_Metagenomic_Std_ATCC_MSA-1003_PacBio_HiFi_Reads_FASTQ_subreads.fastq.gz
```

笔者实测下载玉米HiFi数据,压缩文件大小40Gb,耗时大约1个半小时,放在后台运行即可。

感兴趣的读者可以去github查看SRA-Explorer的源码: <a href="https://github.com/ewels/sra-explorer">https://github.com/ewels/sra-explorer</a>
还可以将index.html下载到本地运行。

Aspera有了SRA-Explorer, 才香。

SRA-Explorer的fastq数据其实是通过European Nucleotide Archive(ENA)数据库获取的。

如果不知道具体的SRA编号,还可以根据自己的需求模糊搜索数据。比如。想下载拟南芥的ONT数据:



获得12条记录,其中有一个sequel数据误入,其它的都是ONT数据哦。当然还可以重新调整关键词,获得更精准的搜索!

